

# PSOP 实验大纲

## 双主实验设计与执行框架

### 实验目标

验证 PSOP 在物理制造与 RTFM 数字工程中的执行增益

### 实验对象

3D 打印小备件  
SHENZHEN I/O puzzle

### 核心机制

PSkill 编译、状态管理、证据检查、Final Verify

### 评估维度

成功率、false success、完成时间、证据完整率、能力门槛

# 目录

覆盖实验命题、任务设计、执行流程、数据采集、分析方法与风险控制。

|                                        |           |
|----------------------------------------|-----------|
| <b>1. 总览：实验命题、双任务组合与核心链路</b>           | <b>4</b>  |
| 1.1 核心实验命题                             | 4         |
| 1.2 开展双主实验的必要性与合理性                     | 4         |
| 1.3 双主实验的互补性                           | 5         |
| 1.4 PSOP 的不可替代链路                       | 5         |
| 1.5 研究问题与假设矩阵                          | 6         |
| 1.6 核心假设的操作化表达                         | 7         |
| <b>2. 实验设计：工具条件、能力分组与样本量</b>           | <b>7</b>  |
| 2.1 四个工具条件                             | 7         |
| 2.2 不同任务下 Manual 的具体材料                 | 8         |
| 2.3 能力评分与分组                            | 8         |
| 2.4 样本量设计                              | 9         |
| 2.5 随机化与执行规则                           | 10        |
| <b>3. 主实验 A：3D 打印小备件</b>               | <b>10</b> |
| 3.1 实验定位                               | 10        |
| 3.2 3D 打印任务流                           | 11        |
| 3.3 第一阶段任务梯度                           | 12        |
| 3.4 3D 打印证据与 guard 矩阵                  | 12        |
| 3.5 3D 打印机与实验环境选型                      | 12        |
| 3.5.1 第一阶段只选 FDM / FFF，不选光固化           | 12        |
| 3.5.2 设备类别与定位                          | 13        |
| 3.5.3 推荐设备策略                           | 13        |
| 3.5.4 工具链、材料与附件                        | 14        |
| 3.6 3D 打印 PSkill、EG 与 Tester 设计        | 15        |
| 3.6.1 PSkill contract                  | 15        |
| 3.6.2 Compiler-generated PSOP-EG 节点组   | 15        |
| 3.6.3 Tester 与 World Model             | 16        |
| <b>4. 主实验 B：SHENZHEN I/O 完成 puzzle</b> | <b>16</b> |
| 4.1 实验定位                               | 16        |

- 4.2 任务模式选择 .....17
- 4.3 Puzzle 选择原则 .....17
- 4.4 SHENZHEN I/O 任务流、证据与 guard 矩阵 .....17
- 4.5 SHENZHEN I/O PSkill、EG 与 Tester 设计 .....18
  - 4.5.1 PSkill contract .....18
  - 4.5.2 Compiler-generated PSOP-EG 节点组 .....19
  - 4.5.3 Tester 与 World Model .....19
- 5. 统一执行流程与数据采集 .....20**
  - 5.1 受试者执行流程 .....20
  - 5.2 数据采集 schema .....20
  - 5.3 版本与证据追踪规则 .....21
- 6. 评价指标与数据分析方案 .....22**
  - 6.1 核心评价指标 .....22
  - 6.2 统计分析模型 .....22
  - 6.3 能力门槛曲线的预期表达 .....23
- 7. 机制证明与消融设计 .....23**
  - 7.1 真人实验主对比 .....23
  - 7.2 自动化 ablation .....23
  - 7.3 机制到指标的映射 .....24
- 8. 阶段计划、风险控制与版本冻结 .....24**
  - 8.1 实验阶段计划 .....24
  - 8.2 风险控制矩阵 .....25
  - 8.3 版本冻结规则 .....25
- 9. 第一轮交付物、最小可行版本与最终叙事 .....26**
  - 9.1 第一轮交付物 .....26
  - 9.2 最小可行版本 .....26
  - 9.3 预期成果表达 .....27
  - 9.4 第一轮执行建议 .....27

# PSOP 实验大纲

## 1. 总览：实验命题、双任务组合与核心链路

### 1.1 核心实验命题

本实验要证明的不是“AI 能不能回答问题”，而是：

PSOP 能否把复杂现实任务或复杂手册驱动任务，先描述为 PSkill，再编译成可执行 PSOP-EG，并通过 Runner 的状态管理、证据检查、主动补证、Final Verify、Tester 和 World Model，使不同能力水平的用户更稳定、更快、更安全地完成目标。

### 1.2 开展双主实验的必要性与合理性

PSOP 的核心主张不只是“提供更好的提示词”或“让模型给出更详细的建议”，而是把任务执行过程拆成可编译、可运行、可验证、可复盘的执行图。因此，实验对象必须同时满足两个要求：一方面要包含真实执行中的不确定性、返工和证据缺口；另一方面又要有足够清晰的成功判定，避免评估停留在主观印象。

选择 3D 打印小备件和 SHENZHEN I/O puzzle 作为双主实验，是因为二者分别覆盖 PSOP 最需要被验证的两个能力面：

#### 1. 3D 打印实验验证现实作业闭环的必要性

- 3D 打印不是纯文本任务，用户必须完成测量、建模、切片、设备准备、打印、后处理和装配验证。
- 任务天然包含材料、设备、误差、安全边界和返工成本，能够检验 PSOP 是否真的能管理真实世界状态，而不是只生成看似合理的说明。
- 成功结果可以通过成品照片、关键尺寸测量、装配测试和 final verify 交叉验证，能够有效暴露 false success。

#### 2. SHENZHEN I/O 实验验证手册驱动工程推理的必要性

- SHENZHEN I/O 要求用户从 puzzle spec 和 manual 中抽取约束，并把约束转化为可运行方案。
- 任务成功由 simulation pass、trace、方案解释和截图共同确认，判定更确定、更可复现。
- 该任务可以隔离“读手册、抽规格、定位错误、迭代调试”这些能力，避免真实硬件噪声掩盖 PSOP 的状态化指导效果。

#### 3. 双主实验组合提升结论可信度

- 单做 3D 打印，结果可能被设备稳定性、用户动手能力或材料误差解释掉。
- 单做 SHENZHEN I/O，结果又可能被质疑为只适用于游戏式数字任务。
- 两者组合后，一个提供生态有效性，一个提供内部有效性；一个检验物理执行闭环，一个检验确定性工程推理；一个暴露现实成本，一个提供精确判定。

#### 4. 任务规模与风险可控

- 3D 打印小备件成本低、周期短、风险可控，适合做多条件、多能力分组对照。

- SHENZHEN I/O 不依赖外部硬件，能稳定收集 trace、失败类型和调试路径。
- 二者都能形成结构化数据集，便于比较 Manual、Generic AI、PSOP Basic 和 PSOP Full。

| 合理性维度 | 3D 打印小备件                     | SHENZHEN I/O puzzle                              | 对 PSOP 的验证意义                             |
|-------|------------------------------|--------------------------------------------------|------------------------------------------|
| 任务真实性 | 有实体材料、设备状态、测量误差和装配反馈         | 有工程规格、芯片约束、时序和资源限制                               | 覆盖真实世界执行与数字工程执行                          |
| 成功判定  | 成品可拍照、可测量、可装配                | simulation pass、trace 和方案解释可复核                   | 避免只靠用户自报或模型自评                            |
| 证据链   | 测量照片、模型文件、切片截图、打印结果、fit test | spec 抽取、manual 引用、simulation log、pass screenshot | 检验 evidence checkpoint 与 final verify    |
| 失败类型  | 测量错误、模型错误、切片错误、打印失败、装配失败     | 规格遗漏、manual 误读、逻辑错误、资源冲突、调试失败                    | 检验 guard、active probe 与 tester hardening |
| 实验可控性 | 通过统一设备、耗材、模板和验收夹具控制变量        | 通过固定 puzzle、manual 和评分标准控制变量                     | 同时获得可执行性和可复现性                            |

这两个实验并不是任意挑选的示例，而是围绕 PSOP 的关键 claim 设计的最小高覆盖组合：既能看见现实任务中的执行摩擦，也能看见手册驱动任务中的状态推理；既能评估最终成功率，也能追踪中间状态、证据完整率和错误成功率。

### 1.3 双主实验的互补性

| 主实验                    | 实验简称              | 证明对象                      | 任务性质            | 关键成功证据                                                  |
|------------------------|-------------------|---------------------------|-----------------|---------------------------------------------------------|
| 3D 打印小备件               | PrintOps-Physical | PSOP 能否把真实需求推进到物理成品       | 低成本、真实物理世界任务    | 成品照片、尺寸测量、装配测试、final verify                             |
| SHENZHEN I/O 完成 puzzle | RTFM-Digital      | PSOP 能否把复杂手册和工程规则转化为状态化指导 | 确定性 RTFM 数字工程任务 | spec 抽取、manual 引用、simulation trace、pass screenshot、方案解释 |

两个任务组合在一起比单独做游戏或单独做真实设备更强：

#### 1. 3D 打印任务证明现实世界闭环

- 用户必须完成测量、建模、切片、打印、后处理、装配测试。
- 任务有真实材料成本、设备状态、物理误差和安全边界。
- 成功不能只靠语言判断，必须由实体成品和证据验证。

#### 2. SHENZHEN I/O 任务证明 RTFM 与状态化推理

- 用户必须阅读 puzzle spec 和 manual。
- 任务有确定性 simulation 反馈。
- 成功不能只靠“看起来合理”，必须由游戏 pass 和方案解释验证。

### 1.4 PSOP 的不可替代链路

实验必须坚持一个原则：**PSOP-EG 必须由 PSkill 编译生成，不能把 EG 当成手写流程图。**

PSkill source

→ Skill Operational Contract

→ Compiler

→ Compiler-generated PSOP-EG artifact

→ Validator

→ Tester + World Model hardening

→ Recompile / freeze EG revision

→ Runner executes EG

→ Session Token / Trace / Evidence / Result

对应交付物不是“两份 PSkill + 两份人工 EG”，而是：

1. 3D 打印链路
- PSkill-Desktop3DPrint-FunctionalSparePart

◦ Compiler-generated PSOP-EG for Desktop3DPrint

◦ Tester + WorldModel suite for Desktop3DPrint

◦ 冻结后的 Desktop3DPrint-FunctionalSparePart@rev-xxx
2. SHENZHEN I/O 链路
- PSkill-SHENZHENIO-ManualDrivenPuzzleCompletion

◦ Compiler-generated PSOP-EG for SHENZHEN I/O

◦ Tester + WorldModel suite for SHENZHEN I/O

◦ 冻结后的 SHENZHENIO-ManualDrivenPuzzleCompletion@rev-xxx
3. 问题修复原则
- 如果 tester 发现漏洞，优先修改：

▪ PSkill source

▪ compiler mapping rule

▪ validator rule

▪ world model scenario spec

◦ 然后重新编译 EG。

◦ 不直接手改 EG，避免破坏 PSkill 作为 source of truth 的地位。

1.5 研究问题与假设矩阵

| 编号 | 要回答的问题                                | 对应假设    | 主要指标                        | 预期方向                                                     |
|----|---------------------------------------|---------|-----------------------------|----------------------------------------------------------|
| Q1 | PSOP 是否比 Manual / Generic AI 提高任务成功率？ | H1      | SuccessRate                 | PSOP Basic > Manual / Generic AI; PSOP Full > PSOP Basic |
| Q2 | PSOP 是否降低低能力用户完成复杂任务的门槛？              | H2      | AbilityThreshold_80、低能力组成功率 | 低能力用户在 PSOP 条件下提升最大                                      |
| Q3 | PSOP 是否减少 false success？              | H3      | FalseSuccessRate            | PSOP < Generic AI                                        |
| Q4 | PSOP-EG 的状态管理是否使任务更稳定推进？              | H4      | 状态收敛时间、关键节点到达率              | PSOP 更快、更稳定到达关键状态                                        |
| Q5 |                                       | H4 / H5 | 证据完整率、final verify 失败率      | PSOP Full 最优                                             |

| 编号 | 要回答的问题                                         | 对应假设  | 主要指标                          | 预期方向             |
|----|------------------------------------------------|-------|-------------------------------|------------------|
|    | Evidence、Active Probe、Final Verify 是否减少跳步和伪完成？ |       |                               |                  |
| Q6 | Tester + World Model hardening 是否带来增益？         | H5    | PSOP Basic vs Full 差异         | Full 错误率更低、证据更完整 |
| Q7 | PSOP 的优势是否同时出现在物理任务和数字工程任务中？                   | H1-H5 | ToolCondition × TaskFamily 交互 | 两类任务都有效，效果大小允许不同 |

## 1.6 核心假设的操作化表达

| 假设                           | 操作化表达                                                                                                                                                                      | 解释                                                                                       |
|------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------|
| H1: PSOP 提高任务成功率             | <code>SuccessRate(PSOP Basic) &gt; SuccessRate(Manual) ; SuccessRate(PSOP Basic) &gt; SuccessRate(Generic AI) ; SuccessRate(PSOP Full) &gt; SuccessRate(PSOP Basic)</code> | 证明 PSOP 不只是聊天提示，而是结构化执行系统                                                                |
| H2: PSOP 降低能力门槛              | 低能力用户 + PSOP Full $\approx$ 中能力用户 + Generic AI，甚至 > 中能力用户 + Manual                                                                                                         | 证明 PSOP 对新手最有价值                                                                          |
| H3: PSOP 降低 false success    | <code>FalseSuccessRate(PSOP) &lt; FalseSuccessRate(Generic AI)</code>                                                                                                      | 3D 打印中防止尺寸/装配伪成功；SHENZHEN I/O 中防止未 pass 却声称完成                                            |
| H4: 状态管理有效                   | 关键状态更快、更稳定到达                                                                                                                                                               | 3D 打印关注测量、建模、切片、打印、装配、final verify；SHENZHEN I/O 关注 spec、manual、simulation、diagnosis、pass |
| H5: Tester + World Model 有增益 | PSOP Full 比 PSOP Basic 更低错误率、更高证据完整率                                                                                                                                       | 证明持续改进飞轮，而不只是一次性流程设计                                                                     |

# 2. 实验设计：工具条件、能力分组与样本量

## 2.1 四个工具条件

| 条件                      | 用户可用资源               | 包含的机制       | 明确不包含                                                                                            | 实验意义            |
|-------------------------|----------------------|-------------|--------------------------------------------------------------------------------------------------|-----------------|
| Condition A: Manual     | 静态说明书、任务说明、安全提示、验收标准 | 无交互、无状态管理   | 无 AI、无证据 checkpoint、无 final verify                                                               | 代表传统 SOP / 文档指导 |
| Condition B: Generic AI | 固定一个普通 AI 模型，可自由对话   | 自然语言问答、通用建议 | 无 PSkill、无 compiled EG、无 Session Token、无强制 evidence checkpoint、无 active probe、无 tester hardening | 代表自由聊天式 AI 指导   |
|                         | PSkill 编译出的 PSOP-EG  |             |                                                                                                  |                 |

| 条件                      | 用户可用资源           | 包含的机制                                                                                                                                                       | 明确不包含                                                           | 实验意义                          |
|-------------------------|------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------|-------------------------------|
| Condition C: PSOP Basic |                  | Session Token、instruct/evaluate 节点、evidence requirement、wait checkpoint、retry / need_more_evidence / abort、final verify、基础 LLM evaluator                    | 无大规模 tester hardening、无 world model 反例强化、无 experience ledger 优化 | 证明 PSkill → EG → Runner 的基础价值 |
| Condition D: PSOP Full  | Hardened PSOP-EG | Basic 全部机制，加 positive / negative / reverse / counterfactual tester、scripted world model、修订后的 PSkill / compiler rule、重新编译后的 hardened EG、初步 experience ledger | 不允许直接手改 EG                                                      | 证明 PSOP 的持续改进飞轮               |

## 2.2 不同任务下 Manual 的具体材料

### 1. 3D 打印任务

- 任务说明。
- 打印机快速入门。
- 切片软件基础说明。
- 安全提示。
- 验收标准。

### 2. SHENZHEN I/O 任务

- 游戏内 puzzle spec。
- 游戏内 manual。
- 实验任务说明。

## 2.3 能力评分与分组

实验保留 30 / 60 / 90 的直觉分组，但形式化为 100 分能力评分。

| 维度             | 分值 | 说明                 | 对 3D 打印的相关性 | 对 SHENZHEN I/O 的相关性 |
|----------------|----|--------------------|-------------|---------------------|
| 通用理解与问题分解      | 20 | 阅读说明、拆解任务、识别关键条件   | 中           | 高                   |
| 数字工具能力         | 20 | 手机、电脑、文件上传、截图、软件操作 | 中           | 高                   |
| 动手与测量能力        | 20 | 卡尺、装配、观察缺陷、设备操作    | 高           | 低                   |
| 编程 / 逻辑 / 电路基础 | 20 | 条件逻辑、状态追踪、简单程序理解   | 低           | 高                   |
| 安全与规范意识        | 20 | 是否会停下来检查风险、保留证据    | 高           | 中                   |



| 分组   | 分数范围   | 描述                   | 预期 PSOP 增益         |
|------|--------|----------------------|--------------------|
| 低能力组 | 0-40   | 基本无相关经验              | 最大                 |
| 中能力组 | 41-70  | 有基础工具和学习能力           | 中等                 |
| 高能力组 | 71-100 | 有工程、编程、设备、3D 打印或电子基础 | 可能主要体现在减少错误和提升证据质量 |

分析时不只看总分，也看子维度：

- 3D 打印更依赖：
  - 动手与测量能力；
  - 安全与规范意识；
  - 基础数字工具能力。
- SHENZHEN I/O 更依赖：
  - 通用理解与问题分解；
  - 编程 / 逻辑 / 电路基础；
  - manual 阅读与状态追踪。

## 2.4 样本量设计

| 版本    | 设计公式                 | 人数 | 每人任务                                  | 总 run 数 | 主要目的                         |
|-------|----------------------|----|---------------------------------------|---------|------------------------------|
| Pilot | 3 能力组 × 4 工具条件 × 2 人 | 24 | 1 个 3D 打印任务 + 1 个 SHENZHEN I/O puzzle | 48      | 校准流程、任务难度、评分标准和 PSOP-EG 稳定性  |
| 主实验   | 3 能力组 × 4 工具条件 × 5 人 | 60 | 同上                                    | 120     | 产出第一版严肃白皮书、内部验证报告或 arXiv 初稿  |
| 增强版   | 3 能力组 × 4 工具条件 × 8 人 | 96 | 同上                                    | 192     | 支持能力门槛曲线和 mixed-effects 统计模型 |

Pilot 重点不追求统计显著，而是验证：

1. 任务可控性
  - 打印时间是否合理。
  - SHENZHEN I/O puzzle 是否过难或过易。
  - 任务 variant 是否公平。
2. 工具条件可比性
  - 用户是否理解 PSOP。
  - PSOP-EG 是否卡死。
  - Generic AI 是否直接给出完整答案。
3. 测量系统可靠性
  - 评分标准是否清晰。
  - 专家评分是否一致。
  - 证据提交是否足够支撑 final verify。

## 2.5 随机化与执行规则

- 任务顺序随机化
  - 一半用户先做 3D 打印。
  - 一半用户先做 SHENZHEN I/O。
- 工具条件固定
  - 一个用户在两个任务中使用同一工具条件。
  - 避免用户在不同工具之间迁移策略。
- 任务 variant 随机分配
  - 3D 打印可以在同类小备件参数上随机化。
  - SHENZHEN I/O 可以在 2-3 个难度相近 puzzle 中随机化。
- 实验环境固定
  - 固定模型版本、工具版本、PSkill revision、compiler version、EG revision。
  - 禁止外部搜索，或统一设置联网条件。

## 3. 主实验 A：3D 打印小备件

### 3.1 实验定位

| 项目        | 内容                                                     |
|-----------|--------------------------------------------------------|
| 实验名称      | PrintOps-Physical: Functional Spare Part Manufacturing |
| 对应 PSkill | PSkill-Desktop3DPrint-FunctionalSparePart              |
| 编译产物      | Desktop3DPrint-FunctionalSparePart@rev-xxx             |
| 核心目标      | 用户根据简单真实需求，完成小型功能性备件的制造闭环                              |
| 第一阶段建议任务  | 线缆固定卡扣                                                 |
| 不建议第一阶段目标 | 高强度承重件、医疗件、食品接触件、电气安全关键件、精密工业件                         |

3D 打印小备件比 FoodPrint 更适合作为主实验，因为它具备：

1. 真实功能性
  - 成品需要装配或夹持。
  - 不是纯展示物。
2. 成本可控
  - 单件耗材少。
  - 失败可记录、可重复。
3. 评价明确
  - 有尺寸阈值。

- 有装配测试。
- 有照片 / 视频证据。

#### 4. 可连接后续商业闭环

- 第一阶段用实验室内桌面打印机控制变量。
- 第二阶段可扩展到线上 3D 打印服务平台模拟下单或真实下单。

## 3.2 3D 打印任务流

### 理解需求

- 测量尺寸
- 选择 / 生成参数化模型
- 检查可打印性
- 切片
- 打印
- 后处理
- 测量成品
- 装配测试
- 提交证据
- final verify

按 PSOP 状态拆分为：

#### 1. 需求与边界确认

- 理解备件用途。
- 判断是否属于低风险、非承重、非医疗、非食品接触任务。
- 超出适用边界时 abort / escalate。

#### 2. 测量与参数确认

- 测量线缆、轴、安装板或孔距。
- 记录单位，统一为 mm。
- 使用卡尺照片和数值截图作为证据。

#### 3. 建模与可打印性检查

- 选择 OpenSCAD 参数化模板。
- 输入测量值生成 STL / 3MF。
- 检查壁厚、孔径、尺寸、支撑需求和平台边界。

#### 4. 切片与打印执行

- 固定 slicer、profile、材料和打印机。
- 保存 slicer project、G-code hash、切片截图。
- 记录首层照片和打印完成照片。

#### 5. 成品验证

- 测量关键尺寸。
- 执行装配 / 夹持 / 扭转测试。
- 提交 final evidence。
- 由 final verify 判断成功、失败或需要补证。

3.3 第一阶段任务梯度

| 任务                    | 阶段       | 目标                    | 用户关键动作                                    | 难点                 | 成功标准                                                 |
|-----------------------|----------|-----------------------|-------------------------------------------|--------------------|------------------------------------------------------|
| Task A: 线缆固定卡扣        | Pilot 首选 | 为指定直径线缆和固定位置打印功能性卡扣   | 测量线缆直径、测量固定位置厚度、输入参数、生成模型、切片、打印、安装测试、提交证据 | 单位、夹持间隙、壁厚、首层质量    | 线缆能放入；能夹持；不明显松脱；不易断裂；关键尺寸误差在阈值内；证据完整；final verify 通过 |
| Task B: 旋钮替代件         | 第二阶段     | 为标准轴打印可用旋钮            | 测量轴径、设置孔径公差、打印、套轴、旋转测试                    | 轴径测量、孔径公差、防滑、扭转测试  | 能套上轴；不开裂；能旋转；不严重打滑；尺寸合理                              |
| Task C: 传感器 / 小模块安装支架 | 第三阶段     | 为小传感器、摄像头模块或开发板打印安装支架 | 测量孔距、确定方向、切片、安装                           | 孔距、安装方向、螺丝孔、支撑、稳定性 | 能安装；方向正确；孔位可用；结构稳定；证据完整                              |

3.4 3D 打印证据与 guard 矩阵

| 阶段           | 必要证据                                    | 关键 guard                   | 失败 / 补证路径                                          |
|--------------|-----------------------------------------|----------------------------|----------------------------------------------------|
| 需求确认         | 任务描述、用途说明                               | 高风险用途必须 abort / escalate   | 用户改选低风险任务或由实验员处理                                   |
| 测量           | 测量值、卡尺照片、单位说明                           | 没有测量值不能生成模型；测量值异常必须重新测量    | need_more_evidence / retry_measurement             |
| 建模           | 参数截图、模型预览、STL / 3MF 文件                  | 模型不可打印不能切片；壁厚过薄不能进入打印      | 修改参数或模板                                            |
| 切片           | 切片截图、slicer profile、材料、预计时间、G-code hash | 切片参数缺失不能打印                 | 补充截图或重新切片                                          |
| 打印           | 打印开始照片、首层照片、完成照片                        | 首层失败必须 retry 或 abort       | 记录失败，允许按规则重试                                       |
| 后处理与测量       | 成品照片、关键尺寸测量照片                           | 没有成品照片不能 final verify      | 补拍或重新测量                                            |
| 装配测试         | 装配照片或视频、测试结果                            | 没有装配测试不能 success           | 补做 fit test                                        |
| Final Verify | 全部证据包                                   | 证据不完整、功能失败、安全违规都不能 success | terminal_failure / need_more_evidence / escalation |

3.5 3D 打印机与实验环境选型

3D 打印实验的目标不是考验用户调机能力，而是验证 PSOP 能否管理“需求到成品”的状态化制造流程。因此设备优先级是：稳定、低成本、低噪声、低维护、可重复、证据可采集。

3.5.1 第一阶段只选 FDM / FFF，不选光固化

| 维度    | FDM / FFF     | 树脂光固化             | 第一阶段结论       |
|-------|---------------|-------------------|--------------|
| 耗材成本  | PLA / PETG 便宜 | 树脂和后处理耗材更复杂       | FDM 更合适      |
| 安全门槛  | 相对低           | 涉及酒精清洗、UV 固化、树脂废液 | 避免引入安全变量     |
| 后处理   | 去支撑、去毛刺即可     | 清洗、固化、废液处理        | FDM 更可控      |
| 功能小备件 | 适合            | 更适合高精度模型          | FDM 与任务目标更匹配 |

| 维度     | FDM / FFF  | 树脂光固化       | 第一阶段结论      |
|--------|------------|-------------|-------------|
| 失败可观察性 | 首层、翘曲、断裂直观 | 失败机制更难解释给新手 | FDM 更适合用户实验 |

3.5.2 设备类别与定位

| 类别             | 代表设备                               | 优点                          | 风险                            | 推荐定位                                       |
|----------------|------------------------------------|-----------------------------|-------------------------------|--------------------------------------------|
| 新手友好型高稳定打印机    | Bambu Lab A1 mini / A1             | 上手快、自动化程度高、适合低能力用户、首层和校准问题少 | 生态相对封闭；云端 / 账号 / 远程控制可能引入变量   | 第一阶段主设备                                    |
| 开源 / 可审计友好型打印机 | Original Prusa MINI+ / Prusa MK 系列 | 生态开放、文档清晰、适合作为研究环境、利于复现     | 对完全新手可能不如 Bambu 省心；采购维护成本可能更高 | Reference printer / reproducibility branch |
| 低成本高可及性打印机     | Creality Ender-3 V3 SE 及同级机型       | 成本低、用户群大、接近普通创客环境           | 调机变量更强，可能污染主实验                | 第二阶段 robustness test                       |

3.5.3 推荐设备策略

1. Pilot 主设备

- 使用 2-3 台同型号新手友好型 FDM 打印机。
- 推荐：Bambu Lab A1 mini 或 Bambu Lab A1。
- 选择规则：
  - 所有备件都小于 120 mm：优先 A1 mini。
  - 需要更大支架、治具或多件排布：优先 A1。
- 固定变量：
  - 固件版本。
  - Bambu Studio 版本。
  - 耗材品牌和批次。
  - 打印 profile。
  - 是否联网、是否启用自动检测功能。

2. Reference / 复现实验设备

- 增加 1 台 Prusa MINI+ 或类似 open/reproducible 设备。
- 作用：
  - 验证 PSOP 不只适用于单一品牌。
  - 支持论文中的 reproducibility。
  - 对比封闭生态和开放生态。
  - 测试 PrusaSlicer / 本地切片流程。

3. 第一阶段不建议使用

- 树脂打印机。
- 大尺寸打印机。
- 高速 CoreXY 高级机。
- 需要大量手动调平的老式打印机。
- 多喷头 / 多材料复杂设备。
- 改装机或维护状态不稳定的二手机。

3.5.4 工具链、材料与附件

| 类别          | 第一阶段选择                                                                                                   | 第二阶段扩展        | 选择理由                                  |
|-------------|----------------------------------------------------------------------------------------------------------|---------------|---------------------------------------|
| CAD / 参数化建模 | OpenSCAD 参数化模板                                                                                           | FreeCAD       | 参数清楚、易记录、tester 可生成尺寸变体、PSOP 可验证参数合理性 |
| 切片软件        | Bambu 设备用 Bambu Studio; Prusa / 通用设备用 PrusaSlicer                                                        | 固定多 slicer 对照 | 固定工具链，降低版本变量                          |
| 文件格式        | OpenSCAD source、STL、3MF、slicer project file、G-code、final photo/video、measurement photo、fit-test evidence | 增加在线平台订单文件    | 保留完整可追溯链路                             |
| 耗材          | PLA 或 PLA+                                                                                               | PETG          | 低气味、低翘曲、低安全风险                         |
| 暂不使用材料      | ABS、ASA、Nylon、碳纤增强材料、TPU、高温材料、食品接触材料、阻燃 / 绝缘功能材料                                                         | 后续专项实验        | 避免气味、翘曲、干燥、喷嘴磨损、安全和工艺变量               |
| 颜色          | 统一灰色或白色                                                                                                  | 可按视觉检测需求扩展    | 便于拍照和视觉评估                             |

必须准备的附件分为四类：

1. 测量与装配
  - 数显卡尺。
  - 标准测试轴。
  - 标准线缆。
  - 标准螺丝。
  - 标准安装板。
2. 后处理与安全
  - 去毛刺工具。
  - 小螺丝刀。
  - 尖嘴钳。
  - 防烫提示牌。
  - 灭火器或消防毯。
3. 证据采集
  - 摄像头 / 手机支架。
  - 实验台编号牌。
  - 零件标签贴纸。
4. 成本与废料记录
  - 耗材称重设备。
  - 废料盒。

## 3.6 3D 打印 PSkill、EG 与 Tester 设计

### 3.6.1 PSkill contract

| 模块                    | 内容                                                                                                                                                                                                                                                                                                                                                                                 |
|-----------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Goal                  | 用户制造一个低风险、小尺寸、非承重、非医疗、非食品接触的功能性小备件，并通过装配验证                                                                                                                                                                                                                                                                                                                                         |
| Applicability: 适用     | 小型塑料备件；PLA / PETG 可打印；非关键承重；非高温环境；非电气安全关键件；可通过简单尺寸和装配测试验证                                                                                                                                                                                                                                                                                                                          |
| Applicability: 不适用    | 医疗器械；食品接触件；高温环境；车辆 / 安全结构件；高强度承重件；电气绝缘关键件；法规管制零件；需要精密公差工业件                                                                                                                                                                                                                                                                                                                         |
| Workflow Steps        | understand_requirement → check_scope_and_safety →<br>collect_measurements → validate_measurements →<br>select_template → generate_model →<br>check_model_printability → choose_material →<br>choose_orientation → slice_model →<br>review_slicer_settings → start_print →<br>monitor_first_layer → complete_print → post_process →<br>measure_final_part → fit_test → final_verify |
| Evidence Requirements | 测量值、卡尺照片、参数截图、模型预览、切片截图、打印开始照片、首层照片、成品照片、尺寸测量照片、装配测试照片或视频                                                                                                                                                                                                                                                                                                                          |
| Completion Criteria   | 成品存在；尺寸符合；功能通过；证据完整；没有安全违规；final verify 通过                                                                                                                                                                                                                                                                                                                                         |

### 3.6.2 Compiler-generated PSOP-EG 节点组

| 节点组   | EG 节点                                                                                                                                  |
|-------|----------------------------------------------------------------------------------------------------------------------------------------|
| 启动与边界 | start_printops_task ; understand_requirement ;<br>verify_scope_and_safety                                                              |
| 测量    | instruct_measurements ; evaluate_measurements                                                                                          |
| 建模    | generate_model_from_template ;<br>evaluate_model_printability                                                                          |
| 切片    | instruct_slicing ; evaluate_slicer_settings                                                                                            |
| 打印    | instruct_print_start ; evaluate_first_layer ;<br>wait_for_print_completion                                                             |
| 成品验证  | evaluate_final_part_photo ;<br>instruct_measure_final_part ;<br>evaluate_final_measurements ; instruct_fit_test ;<br>evaluate_fit_test |
| 终局    | final_verify_part ; terminal_success ;<br>terminal_failure_or_escalation                                                               |

3.6.3 Tester 与 World Model

| 测试类型                 | 生成内容                                                                                                                                                                 | 检查目标                             |
|----------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------|
| Positive cases       | 用户测量正确、参数合理、模型可打印、切片正确、打印成功、装配成功、final verify 成功                                                                                                                     | 正常路径能否顺利完成                       |
| Negative cases       | 未测量、直径/半径混淆、mm/cm 混淆、孔径小于轴径、壁厚过薄、模型超出平台、切片无支撑、首层失败、成品无法装配、照片模糊、用户要求跳过检查、声称成功但无证据                                                                                     | guard 是否阻止跳步和伪成功                 |
| Reverse cases        | success_without_measurement 、 success_without_final_photo 、 success_without_fit_test 、 unsafe_part_accepted 、 wrong_dimension_accepted 、 failed_print_marked_success | 从坏状态反推最短违规路径，找 EG 漏洞             |
| Scripted World Model | 用户能力、测量误差、单位错误、打印失败、首层失败、孔径偏小、支撑缺失、材料不合适、漏拍照片、过早声称完成                                                                                                                 | 模拟现实错误分布，生成测试场景和 belief/proposal |

World Model 的边界：

- 只生成 test scenarios 和 belief/proposal。
- 不能写 facts。
- 不能绕过 final verify。

4. 主实验 B：SHENZHEN I/O 完成 puzzle

4.1 实验定位

| 项目        | 内容                                                    |
|-----------|-------------------------------------------------------|
| 实验名称      | RTFM-Digital: Manual-Driven Circuit Puzzle Completion |
| 对应 PSkill | PSkill-SHENZHENIO-ManualDrivenPuzzleCompletion        |
| 编译产物      | SHENZHENIO-ManualDrivenPuzzleCompletion@rev-xxx       |
| 核心目标      | 用户在不直接复制完整答案的条件下，基于 puzzle spec 和 manual 完成指定 puzzle  |
| 主实验模式     | Coaching Mode                                         |
| 补充模式      | Completion Mode                                       |

SHENZHEN I/O 适合作为 RTFM 环境，因为它要求用户构建电路、编写代码、阅读 datasheets / reference guides / technical diagrams，并通过 simulation 验证。



## 4.2 任务模式选择

| 模式              | AI / PSOP 可做                             | AI / PSOP 不可做                     | 适用位置  | 证明对象                     |
|-----------------|------------------------------------------|-----------------------------------|-------|--------------------------|
| Coaching Mode   | 指导用户理解 spec、阅读 manual、抽取 IO、选择组件、调试、分析失败 | 不能直接给完整最终电路和完整代码                  | 第一主实验 | PSOP 是否增强人的 RTFM 和工程执行能力 |
| Completion Mode | 可以给出完整方案，用户实现并验证                         | 仍需 final verify 和 pass screenshot | 补充实验  | 端到端完成能力                  |

主实验使用 Coaching Mode 的原因：

1. 公开 puzzle 可能已被大模型记住。
2. 直接给答案会把实验变成“模型记忆测试”。
3. Coaching Mode 更能验证 PSOP 的状态化指导、证据管理和调试闭环。

## 4.3 Puzzle 选择原则

选择 puzzle 时应满足：

1. **难度适中**
  - 不太简单。
  - 不太难。
  - 30-60 分钟内有机会完成。
2. **需要 RTFM**
  - 输入输出明确。
  - 需要定位 manual section。
  - 需要理解组件行为或时序。
3. **反馈可验证**
  - 有 simulation feedback。
  - 可以截图保存失败和成功状态。
  - 不以极致优化为目标，只看能否正确完成。
4. **降低记忆污染**
  - 避免网络上最常见的标准解。
  - 记录用户是否玩过 Zachtronics 游戏。
  - 后续可自建 SHENZHEN-like puzzle。

## 4.4 SHENZHEN I/O 任务流、证据与 guard 矩阵

| 阶段        | 用户动作               | 必要证据                   | 关键 guard                               |
|-----------|--------------------|------------------------|----------------------------------------|
| 读题        | 阅读 puzzle spec     | puzzle spec screenshot | 没有 spec screenshot 不能进入 final evidence |
| 规格抽取      | 提取输入、输出、时序、约束      | 用户提取的 IO 要求            | 没有 spec extraction 不能进入 design         |
| 定位 manual | 找相关 manual section | manual section 截图或引用   |                                        |

| 阶段           | 用户动作                      | 必要证据                             | 关键 guard                                   |
|--------------|---------------------------|----------------------------------|--------------------------------------------|
|              |                           |                                  | 没有 manual reference 不能 claim understanding |
| 方案草案         | 选择组件、描述电路策略               | strategy text、组件列表               | AI 不得直接给完整最终电路和代码                          |
| 搭建与编码        | 放置组件、接线、写初版代码             | 电路截图、代码截图                        | 使用不存在组件 / 指令必须拦截                           |
| simulation   | 运行测试                      | simulation result 截图             | 没有 simulation result 不能 final verify       |
| 失败诊断         | 收集 failure trace、定位原因     | failed trace、诊断说明                | simulation failed 不能 success               |
| 修正与复跑        | 修改电路或代码并复测                | revision screenshot、rerun result | partial pass 不能 success                    |
| 通过与解释        | 提交 pass screenshot、解释核心逻辑 | pass screenshot、方案解释             | 没有 pass screenshot 或解释不能 full success      |
| Final Verify | 汇总证据                      | 全部证据包                            | 违反 coaching policy、证据缺失或未 pass 均失败         |

## 4.5 SHENZHEN I/O PSkill、EG 与 Tester 设计

### 4.5.1 PSkill contract

| 模块                    | 内容                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
|-----------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Goal                  | 用户在不直接复制完整答案的条件下，基于 puzzle spec 和 manual 完成指定 SHENZHEN I/O puzzle                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| Applicability: 适用     | 官方 puzzle；用户可访问游戏内 manual；用户可截图；用户可运行 simulation；用户可提交失败 trace 和最终 pass screenshot                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        |
| Applicability: 不适用    | 需要外部解法数据库；需要隐藏游戏机制；需要 speedrun；需要最优 score；用户已经完整玩过该 puzzle                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
| Workflow Steps        | <code>read_puzzle_spec</code> → <code>extract_io_requirements</code> → <code>identify_manual_sections</code> → <code>summarize_relevant_components</code> → <code>draft_solution_strategy</code> → <code>select_components</code> → <code>place_components</code> → <code>wire_inputs_outputs</code> → <code>write_initial_code</code> → <code>run_simulation</code> → <code>collect_failure_trace</code> → <code>diagnose_failure</code> → <code>revise_circuit_or_code</code> → <code>rerun_simulation</code> → <code>pass_all_tests</code> → <code>explain_solution</code> → <code>final_verify</code> |
| Evidence Requirements | puzzle spec screenshot、用户提取的输入输出要求、相关 manual section、电路截图、代码截图、simulation 失败截图、失败诊断说明、最终 pass screenshot、用户方案解释                                                                                                                                                                                                                                                                                                                                                                                                                                                                                           |
| Completion Criteria   | 游戏显示 puzzle pass；提交 pass screenshot；用户能解释核心逻辑；过程没有直接复制完整答案；final verify 通过                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |

4.5.2 Compiler-generated PSOP-EG 节点组

| 节点组   | EG 节点                                                                                               |
|-------|-----------------------------------------------------------------------------------------------------|
| 启动与读题 | start_shenzhen_task ; instruct_read_spec ; evaluate_spec_understanding                              |
| 手册定位  | instruct_identify_manual_sections ; evaluate_manual_references                                      |
| 规格抽取  | instruct_extract_io_requirements ; evaluate_io_requirements                                         |
| 方案设计  | instruct_draft_strategy ; evaluate_strategy                                                         |
| 搭建与编码 | instruct_build_circuit ; evaluate_circuit_screenshot ; instruct_write_code ; evaluate_code_snapshot |
| 运行与诊断 | instruct_run_simulation ; evaluate_simulation_result ; diagnose_failure                             |
| 修订与复验 | instruct_revision ; evaluate_revision                                                               |
| 终局    | final_verify_puzzle ; terminal_success ; terminal_failure_or_timeout                                |

4.5.3 Tester 与 World Model

| 测试类型                 | 生成内容                                                                                                                                                                   | 检查目标                     |
|----------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------|
| Positive cases       | 正确抽取 IO、正确引用 manual、初始方案部分正确、失败后提交 trace、PSOP 引导诊断、用户修复、最终通过                                                                                                           | 正常 coaching 路径能否推动到 pass |
| Negative cases       | 没读 spec、IO 理解反了、使用不存在 instruction、组件接线错误、代码只过部分测试、simulation failed 却声称完成、只上传代码截图、AI 编造 manual 内容、用户要求跳过解释                                                             | 防止 hallucination、跳步、伪成功  |
| Reverse cases        | success_without_pass_screenshot、success_after_failed_simulation、manual_hallucination_accepted、io_spec_misunderstood_but_design_allowed、direct_solution_policy_violated | 从坏状态反推 guard 漏洞          |
| Scripted World Model | 用户没读 manual、误解时序、接线错误、只会改代码不会看 trace、以为 partial pass 完成、AI 给出不存在组件、AI 忽略 puzzle 约束、用户上传错误截图                                                                            | 模拟常见认知错误和证据错误            |

# 5. 统一执行流程与数据采集

## 5.1 受试者执行流程

| 顺序 | 步骤       | 产出 / 记录                                      | 说明                                           |
|----|----------|----------------------------------------------|----------------------------------------------|
| 1  | 签到与同意书   | consent record                               | 统一实验说明                                       |
| 2  | 能力测评     | ability_score、ability_group、子维度分             | 作为分组和协变量                                     |
| 3  | 工具条件随机分配 | tool_condition                               | Manual / Generic AI / PSOP Basic / PSOP Full |
| 4  | 工具培训     | training completion                          | 只教工具使用，不教任务答案                                |
| 5  | 任务 1     | run record、trace、evidence                    | 任务顺序随机化                                      |
| 6  | 任务后问卷    | satisfaction、difficulty、trust、cognitive load | 记录主观体验                                       |
| 7  | 休息       | break record                                 | 降低疲劳影响                                       |
| 8  | 任务 2     | run record、trace、evidence                    | 使用同一工具条件                                     |
| 9  | 任务后问卷    | 同上                                           | 两任务分别记录                                      |
| 10 | 半结构化访谈   | interview notes                              | 收集失败原因和机制解释                                  |
| 11 | 专家评分     | expert_score、success、false_success           | 统一 rubric                                    |
| 12 | 数据清洗     | clean dataset                                | 对齐版本、证据和时间戳                                  |

## 5.2 数据采集 schema

| 数据表                 | 关键字段                                                                                                                                                                                                                     | 用途            |
|---------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------|
| Participant dataset | participant_id、ability_score、ability_group、五项能力子分、过往经验                                                                                                                                                                   | 分组、协变量、能力门槛分析 |
| Run dataset         | participant_id、tool_condition、task_family、task_variant、start_time、end_time、success、completion_time、expert_score、false_success、intervention_count                                                                         | 主分析表          |
| Survey dataset      | user_satisfaction、perceived_difficulty、cognitive_load、trust、willingness_to_reuse                                                                                                                                         | 用户体验分析        |
| PSOP trace dataset  | PSkill revision、compiler version、EG revision、Session Token snapshots、trace events、node enabled/ready/selected、evidence accepted/rejected、active probe count、final verify result、terminal events、model calls、token usage、 | 机制分析与复现       |

| 数据表                       | 关键字段                                                                                                                                                                                                                                                                                 | 用途                   |
|---------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------|
|                           | tool usage、tester suite version、world model scenario version                                                                                                                                                                                                                         |                      |
| 3D print artifact dataset | printer_id、printer_model、firmware_version、slicer_version、slicer_profile、filament_type、filament_batch、part_type、model_template_version、parameter values、STL hash、G-code hash、print_time、filament_grams、print_failure、measurement_error、fit_test_result、final_part_score、photos/videos | 物理任务质量、成本和失败归因       |
| SHENZHEN artifact dataset | puzzle_id、puzzle_difficulty、mode、manual_sections_used、simulation_runs、failed_runs、circuit_revision_count、code_revision_count、final_pass、pass_screenshot、explanation_score、direct-answer-policy violations                                                                            | RTFM 任务质量、调试成本和策略合规性 |

## 5.3 版本与证据追踪规则

每个 run 都必须保存：

### 1. PSOP 版本

- PSkill revision。
- Compiler version。
- EG revision。
- Tester suite version。
- World Model scenario version。

### 2. 3D 打印 artifact 版本

- CAD template version。
- Parameter values。
- STL hash。
- Slicer version。
- Slicer profile。
- G-code hash。
- Printer ID。
- Filament ID / batch。

### 3. SHENZHEN I/O artifact 版本

- Puzzle ID。
- Puzzle variant。
- Manual section references。
- Circuit revision snapshots。
- Code revision snapshots。

- Simulation result screenshots.

## 6. 评价指标与数据分析方案

### 6.1 核心评价指标

| 指标                 | 公式 / 定义                                                                            | 3D 打印判定                                                                                                           | SHENZHEN I/O 判定                                                                                                                        | 解释重点                         |
|--------------------|------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------|------------------------------|
| 任务成功率              | $\text{SuccessRate} = \frac{\text{成功 run 数}}{\text{总 run 数}}$                      | 专家验收 + final verify 通过                                                                                            | pass screenshot + 方案解释 + final verify 通过                                                                                               | 主效果                          |
| 完成时间               | $\text{CompletionTime} = \text{EndTime} - \text{StartTime}$ ，未完成按 timeout 处理       | 从任务开始到 final verify                                                                                               | 从读题开始到 final verify                                                                                                                    | 不能脱离质量单独解释                   |
| False Success Rate | $\text{FalseSuccessRate} = \frac{\text{声称成功但专家/系统判定失败的 run 数}}{\text{声称成功 run 数}}$ | 尺寸错误、无法装配、证据缺失却声称完成                                                                                               | 未 pass、无 pass screenshot、无法解释却声称完成                                                                                                     | 证明治理能力的关键指标                  |
| 证据完整率              | $\text{EvidenceCompleteness} = \frac{\text{已提交必要证据}}{\text{应提交必要证据}}$              | 测量、模型、切片、打印、成品、装配证据                                                                                               | spec、manual、simulation、pass、解释证据                                                                                                       | 衡量 evidence-driven execution |
| 状态收敛时间             | 到达关键状态的时间戳                                                                         | T_measurements_validated、T_model_generated、T_slicer_reviewed、T_print_completed、T_fit_test_passed、T_final_verified | T_spec_extracted、T_manual_identified、T_initial_design_created、T_simulation_run、T_failure_diagnosed、T_all_tests_passed、T_final_verified | 证明状态管理是否有效                   |
| 返工 / 调试次数          | 重复关键步骤次数                                                                           | 重新测量、重新生成模型、重新切片、重新打印、装配失败                                                                                        | simulation run、failed simulation、circuit revision、code revision                                                                        | 衡量执行摩擦                       |
| 成本指标               | 时间、材料、token、交互轮数等                                                                  | 耗材克数、打印时间、失败材料浪费、设备占用时间、人工干预次数                                                                                    | 用户时间、AI token、交互轮数、无效建议次数                                                                                                              | 衡量真实部署成本                     |

### 6.2 统计分析模型

| 分析目标          | 模型                                                                                                                                     | 重点解释                                      |
|---------------|----------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------|
| 成功率主效果        | $\text{Success} \sim \text{ToolCondition} \times \text{AbilityGroup} \times \text{TaskFamily} + (1$                                    | Participant) + (1                         |
| 完成时间          | $\log(\text{CompletionTime}) \sim \text{ToolCondition} \times \text{AbilityGroup} \times \text{TaskFamily} + (1$                       | Participant) + (1                         |
| False Success | $\text{FalseSuccess} \sim \text{ToolCondition} + \text{TaskFamily} + \text{EvidenceCompleteness}$                                      | 预期 PSOP Full 最低                           |
| 能力门槛曲线        | $P(\text{Success}) = \text{sigmoid}(\alpha + \beta_1 \text{AbilityScore} + \beta_2 \text{ToolCondition} + \beta_3 \text{Interaction})$ | 估计 AbilityThreshold_80，即达到 80% 成功率所需最低能力分 |

### 6.3 能力门槛曲线的预期表达

| 工具         | 80% 成功所需能力 | 预期含义                                   |
|------------|------------|----------------------------------------|
| Manual     | 高          | 传统文档对低能力用户门槛高                          |
| Generic AI | 中高         | 自由对话能帮忙，但缺少状态与证据治理                     |
| PSOP Basic | 中          | 编译 EG 和 evidence checkpoint 已能降低门槛     |
| PSOP Full  | 中低         | Tester + World Model hardening 进一步降低门槛 |

## 7. 机制证明与消融设计

### 7.1 真人实验主对比

|               |
|---------------|
| Manual        |
| vs Generic AI |
| vs PSOP Basic |
| vs PSOP Full  |

该对比用于证明整体系统价值：

- PSOP 是否优于静态 SOP。
- PSOP 是否优于自由聊天式 AI。
- PSOP Full 是否优于 PSOP Basic。
- PSOP 是否在物理任务和数字工程任务中都有效。

### 7.2 自动化 ablation

自动化消融不一定进入真人实验，但必须进入 tester。

| Ablation 条件                       | 移除内容    | 预期暴露的问题                    | 证明机制                                 |
|-----------------------------------|---------|----------------------------|--------------------------------------|
| PSOP without evidence requirement | 移除强制证据  | 用户跳步、证据缺失、false success 上升 | evidence checkpoint 的价值              |
| PSOP without active probe         | 移除主动补证  | 模糊输入被接受、错误测量未被发现           | active probe 的价值                     |
| PSOP without final verify         | 移除终局验证  | 未装配 / 未 pass 被判成功          | final verify 的价值                     |
| PSOP without state memory         | 移除状态记忆  | 重复提问、漏掉前置条件、状态倒退           | Session Token / state management 的价值 |
| PSOP before tester hardening      | 使用未强化版本 | guard 漏洞更多                 | Tester / World Model 之前的 baseline    |
| PSOP after tester hardening       | 使用强化版本  | 错误率下降、证据更完整                | 持续改进飞轮                               |

7.3 机制到指标的映射

| PSOP 机制                        | 应影响的指标                             | 预期表现                   |
|--------------------------------|------------------------------------|------------------------|
| PSkill contract                | 成功率、适用边界违规率                        | 任务边界更清楚，越界更少           |
| Compiler-generated EG          | 状态收敛时间、关键节点到达率                     | 执行更稳定，少跳步              |
| Evidence checkpoint            | 证据完整率、false success                | 证据更完整，伪成功更少            |
| Active probe                   | 测量错误率、manual misunderstanding rate | 关键不确定性更早暴露             |
| Final Verify                   | false success、终局错误                 | 成功判定更严格                |
| Tester / World Model hardening | Basic vs Full 差异                   | Full 在错误率、证据完整率和成功率上更优 |

8. 阶段计划、风险控制与版本冻结

8.1 实验阶段计划

| 阶段                        | 时间    | 核心产出                                                                                                                                             | 主要目标                                                                        |
|---------------------------|-------|--------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| Phase 0: 准备期              | 2-3 周 | 两个 PSkill、两个 compiler-generated EG、两个 validator report、两套 tester suite、两个 scripted world model、3D 打印机与耗材、SHENZHEN I/O 环境、能力测评问卷、专家评分表、安全流程、数据采集表 | 完成实验基础设施                                                                    |
| Phase 1: Pilot            | 2 周   | 24 人、48 runs、pilot 数据、流程问题清单                                                                                                                     | 校准任务难度、打印时间、puzzle 难度、PSOP-EG 稳定性、Generic AI 答案泄漏风险、评分一致性                   |
| Phase 2: Tester hardening | 1-2 周 | positive / negative / reverse / counterfactual / regression cases；重编译后的 EG                                                                       | 修复 PSkill / compiler / validator / world model 漏洞，冻结 Basic / Full revisions |
| Phase 3: 主实验              | 4-6 周 | 60 人、120 runs、主数据集                                                                                                                               | 输出成功率、完成时间、false success、证据完整率、状态收敛曲线、能力门槛曲线、Basic vs Full、失败分类、用户访谈        |
| Phase 4: 扩展验证             | 后续    | 旋钮替代件、传感器支架、线上 3D 打印平台模拟下单、少量真实平台下单、SHENZHEN-like 自建 puzzle、更多 RTFM 环境                                                                           | 验证外推性和商业闭环                                                                  |



## 8.2 风险控制矩阵

| 风险域               | 主要风险                        | 控制措施                                                                                           |
|-------------------|-----------------------------|------------------------------------------------------------------------------------------------|
| 3D 打印安全           | 喷嘴烫伤、热床烫伤、用户误用工具            | 使用 PLA；低风险小件；禁止用户接触喷嘴和热床；实验员处理硬件异常；打印机固定位置；防烫提示和消防设备                                           |
| 3D 打印质量           | 打印失败、材料浪费、设备故障、长时间打印        | 每次实验前校准；首层失败记录但不立即判定用户失败；统一打印机、耗材、profile；所有失败进入 failure taxonomy                              |
| SHENZHEN I/O 公平性  | AI 直接背答案、用户之前玩过、puzzle 难度不均 | 使用 Coaching Mode；记录 Zachtronics 经验；禁止外部搜索；选择不太常见 puzzle；后续自建 SHENZHEN-like puzzle              |
| SHENZHEN I/O 操作门槛 | 用户不会操作界面、截图证据缺失             | 任务前 5 分钟界面训练；要求 pass screenshot；要求用户解释方案                                                       |
| 模型版本              | 模型更新导致结果不可复现                | 固定模型；固定日期窗口；记录模型版本；保存完整对话；统一联网条件                                                               |
| PSOP 版本           | PSkill / EG / tester 变动污染结果 | 锁定 PSkill revision、compiler version、EG revision、tester version、world model version；所有 run 记录版本 |

## 8.3 版本冻结规则

进入真人实验前必须冻结：

### 1. PSOP 侧

- PSkill revision。
- Compiler version。
- EG revision。
- Validator rule version。
- Tester suite version。
- World Model scenario version。

### 2. 任务侧

- 3D 打印任务 variant。
- OpenSCAD template version。
- Printer firmware。
- Slicer version / profile。
- SHENZHEN I/O puzzle ID / variant。

### 3. AI 侧

- Generic AI 模型版本。
- PSOP evaluator 模型版本。
- 联网 / 不联网策略。

如果 Phase 2 发现问题，修复流程必须是：

修改 PSkill / compiler rule / validator rule / world model scenario spec

→ 重新编译 EG

→ 重新跑 tester

→ 通过后 freeze EG revision

→ 进入真人实验

## 9. 第一轮交付物、最小可行版本与最终叙事

### 9.1 第一轮交付物

| 类别                 | 交付物                                                                                                                                                                                           |
|--------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| PSkill             | PSkill-Desktop3DPrint-FunctionalSparePart ; PSkill-SHENZHENIO-ManualDrivenPuzzleCompletion                                                                                                    |
| Compiler Artifacts | Desktop3DPrint-FunctionalSparePart@basic-eg ; Desktop3DPrint-FunctionalSparePart@full-eg ; SHENZHENIO-ManualDrivenPuzzleCompletion@basic-eg ; SHENZHENIO-ManualDrivenPuzzleCompletion@full-eg |
| Tester             | PrintOps positive / negative / reverse / counterfactual suite ; SHENZHEN positive / negative / reverse / counterfactual suite                                                                 |
| World Model        | PrintOps scripted scenario model ; SHENZHEN scripted cognitive/error model                                                                                                                    |
| 实验数据               | Participant dataset ; Run dataset ; Trace dataset ; Evidence dataset ; 3D print artifact dataset ; SHENZHEN artifact dataset ; Survey dataset ; Expert scoring dataset                        |

### 9.2 最小可行版本

| 项目     | MVP 配置                                                                   |
|--------|--------------------------------------------------------------------------|
| 人数     | 24 人 pilot                                                               |
| 条件     | Manual; Generic AI; PSOP Basic; PSOP Full                                |
| 任务     | 3D 打印: 线缆固定卡扣; SHENZHEN I/O: 一个 medium puzzle                            |
| 打印机    | 2 台同型号 Bambu A1 mini 或 A1; 1 台备用同型号机器                                    |
| 统一变量   | PLA; slicer version; 参数化模板; 验收夹具; 模型版本; PSOP revision                    |
| 主要成功指标 | 任务成功率; false success; 完成时间; 证据完整率; 状态收敛时间; 低能力组提升; PSOP Basic vs Full 差异 |

Pilot 进入主实验的建议门槛：

### 1. 效果门槛

- PSOP Full 对低能力用户有明显提升。
- PSOP Full 的 false success 明显低于 Generic AI。

### 2. 流程门槛

- PSOP-EG 不频繁卡死。
- 证据要求不会让用户完全无法推进。
- final verify 能稳定区分成功、失败和需要补证。

### 3. 任务门槛

- 线缆卡扣任务能在可控时间内完成。
- SHENZHEN I/O medium puzzle 不会过难或过易。
- 专家评分一致性可接受。

## 9.3 预期成果表达

实验报告可以围绕如下主张组织：

我们提出 PSOP-Bench v0，包含一个真实物理制造任务和一个确定性 RTFM 数字工程任务。第一个任务要求用户使用桌面 3D 打印机完成一个功能性小备件；第二个任务要求用户在 SHENZHEN I/O 中基于手册完成电路 puzzle。两个任务都由 PSkill 描述，并由 compiler 生成 PSOP-EG。Runner 执行 EG，维护 Session Token、证据、状态和 final verification。Tester 与 World Model 生成正向、负向、反向和反事实测试，用于强化 PSkill / compiler / EG。我们比较 Manual、Generic AI、PSOP Basic 和 PSOP Full 在不同能力用户中的表现，评估成功率、完成时间、错误成功率、证据完整率、状态收敛时间和能力门槛曲线。

预期证明路径不是把 PSOP 描述为普通 agent framework，而是把它呈现为一套：

PSkill source  
→ formal execution graph  
→ governed runtime  
→ evidence-driven execution  
→ test-hardened evolution

的现实作业执行系统。

## 9.4 第一轮执行建议

建议把第一轮实验锁定为：

主实验 1：3D 打印小备件  
主实验 2：SHENZHEN I/O 完成 puzzle

执行策略：

### 1. 3D 打印侧

- 第一阶段优先选择稳定、低噪声、低维护的新手友好型 FDM 设备。
- 减少硬件变量，把实验焦点放在 PSOP 的状态管理和证据闭环上。

### 2. SHENZHEN I/O 侧

- 使用 Coaching Mode。
- 避免实验变成大模型背答案测试。
- 重点验证 RTFM、规格抽取、状态追踪和调试闭环。

### 3. PSOP 工程侧

- 先写 PSkill。
  - 由 compiler 生成 EG。
  - tester 和 world model 发现问题后，修改 PSkill 或 compiler rule。
  - 重新编译 EG。
  - 真人实验只执行冻结后的 EG revision。
-